RETO 1 · BDA / SBD / SAA / PIA / MIA

Vivienda joven en Euskadi

Datos trazables → referencia municipal → orientación explicable

¿Dónde puede vivir una persona joven con su salario?

Proyecto intermodular · BDA / SBD / SAA / PIA / MIA

Una referencia para comparar y orientar. La resolución requiere revisión humana.

Una necesidad cuantificada

Bilbao · EMAL 2024 T4 y salario juvenil OVJ 2024

930,31 €
Renta mensual municipal

1.564 €
Salario neto autonómico

59,48 %
Escenario de esfuerzo

Usuario: servicios de orientación y personas que comparan referencias con su presupuesto.

Beneficio esperado: facilitar una comparación verificable; impacto no medido.

Dos recorridos conectados

Las piezas cumplen funciones distintas

Recogida y análisis · BDA / SBD



Predicción y orientación · SAA / PIA / MIA



Arquitectura vigente; anuncios y modelo conservan unidades separadas.

Fuentes y unidades

No todos los registros representan una vivienda

Recogida

- JSON monetario EMAL: tres capitales.
- HTML: 17 anuncios de dos portales.
- Visesa/Etxebide: 621 promociones.
- INE y OVJ: territorio y contexto.

Conservación

- URL, fecha UTC y estado HTTP.
- Bytes y SHA-256.
- Nulos y rechazos explícitos.
- Sin afirmar disponibilidad actual.

> Demostración: un JSON API y un HTML archivado.

HDFS → Kafka → MongoDB

Guardar, recuperar, transportar y persistir

638
Registros vivienda: 621 + 17

3
Estadísticas API separadas

0
Duplicados nuevos en recarga

- HDFS raw/processed y recuperación idéntica.
- Consumidor confirma offset después de persistir.
- Upsert e identidades estables ante reentrega.

> Mostrar informe real conservado o ejecución de ensayo identificada.

MongoDB: análisis verificable

Consultas, agregaciones, índice y atomicidad

Consultas y pipelines

Cinco consultas útiles, filtros combinados y arrays.

$group, $lookup, $unwind, $facet y otras etapas.

Explain

638 → 4

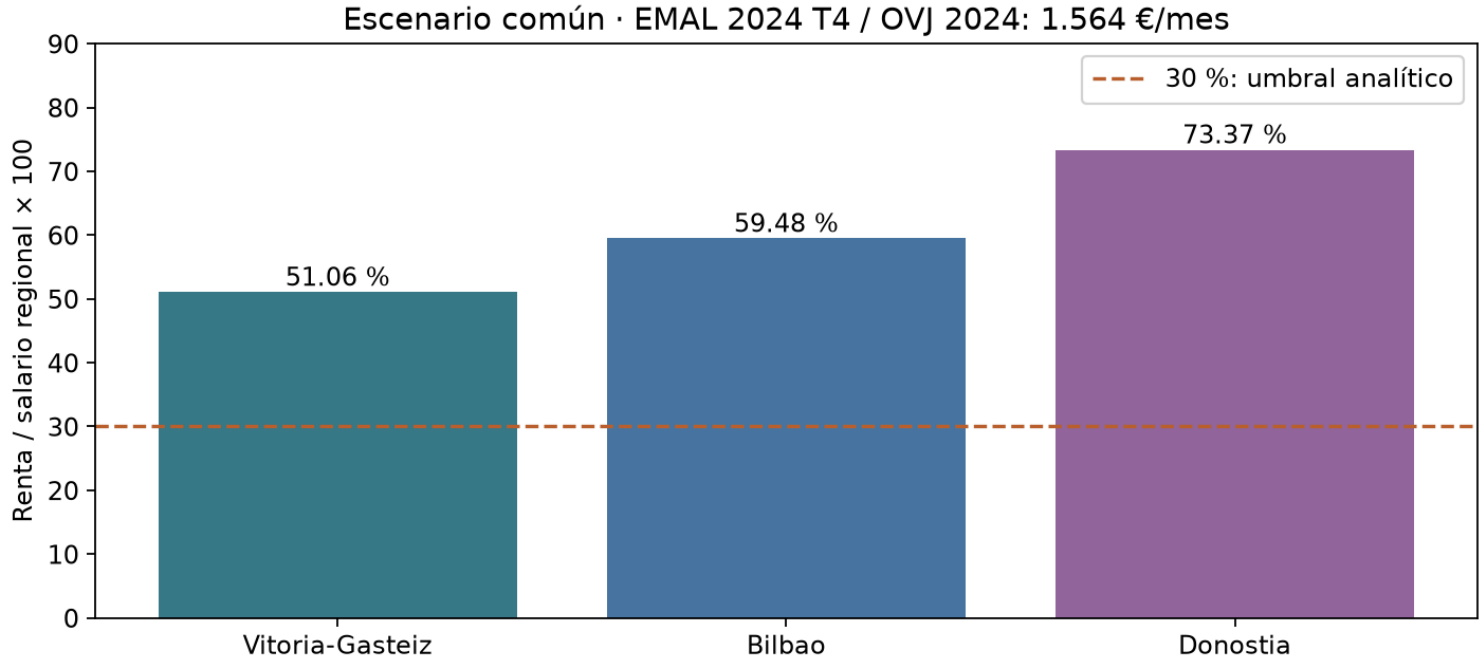
Documentos examinados; mismos cuatro resultados.

Ambos tiempos: 0 ms.

100 incrementos sobre copia aislada: atomicidad, no demanda real.

Comparación territorial

Mismo ingreso de referencia; datos del mismo año



Escenario EMAL 2024 T4 / salario autonómico 2024. No esfuerzo individual observado.

Dataset, EDA y tiempo

768 observaciones municipales · 19 municipios

601
Train · hasta 2023

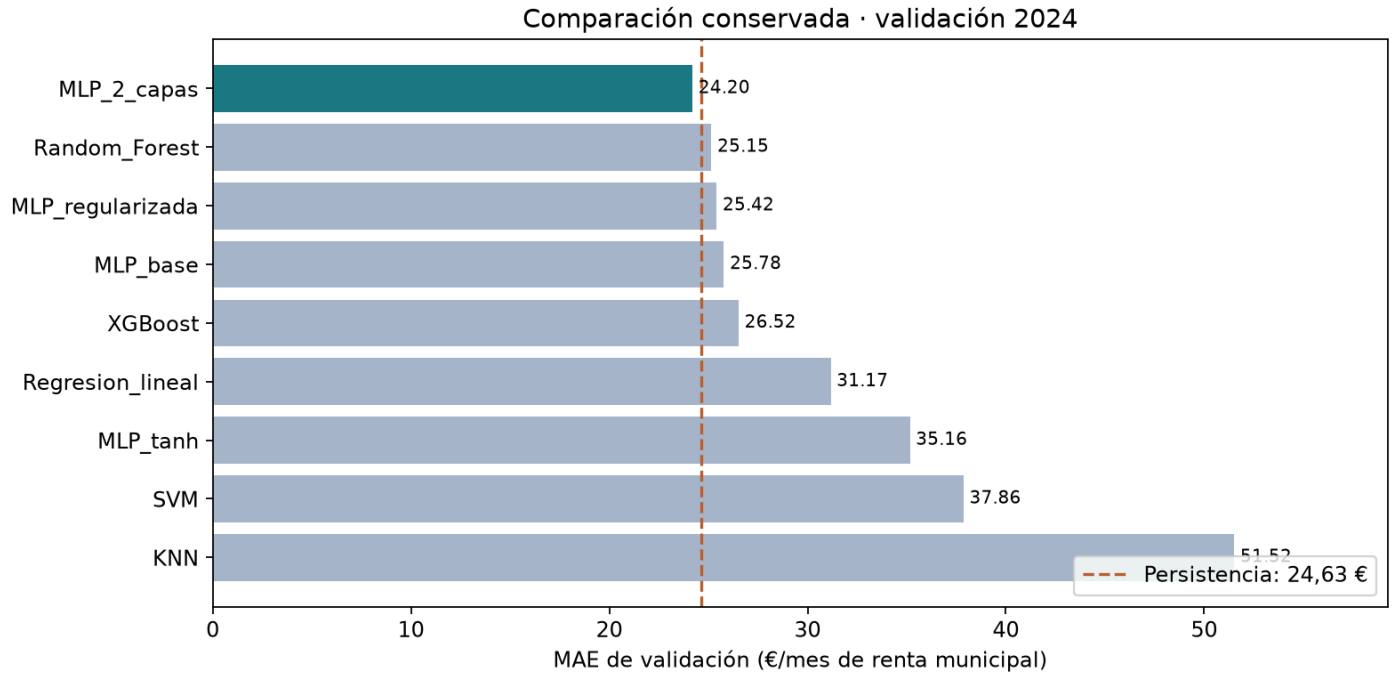
75
Validación · 2024

92
Test · desde 2025

- Cinco EDA comentados y nulos con patrón.
- lag1, lag4 y contratos previos; sin objetivo contemporáneo como entrada.
- Imputación, escalado y one-hot dentro del entrenamiento.
- Validación por trimestres; evaluación retrospectiva a un paso.

Cinco familias y cuatro MLP

Selección por MAE de validación, antes del test



MLP_2_capas: 24,20 €; persistencia: 24,63 €. Diferencia pequeña.

Explicar y evaluar sin reabrir selección

SHAP usa validación; test se conserva

SHAP

30 filas de validación, fondo de train.

Pesan renta_lag1 y renta_lag4.

Contribuciones del modelo, no causas.

Test único · 92 filas

MAE 28,67 €

RMSE 37,93 € · R^2 0,9189

R^2 no es porcentaje de aciertos.

SMOTE auxiliar: F1 0,8254 → 0,8167; no mejora esa métrica.

> Mostrar informe conservado, sin volver a evaluar.

Predicción → regla → ficha

Diez reglas, ocho decisiones y consentimiento

Mismo perfil de prueba

Ingreso 1.500 € · contrato 500 €

Referencia 600 € → consultar

Referencia 1.600 € → alternativas

Los dos importes son prueba del motor.

Recorrido real de la app

Leer referencia y periodo predichos.

Separar esfuerzo declarado y de referencia.

Consentimiento → webhook → ficha.

Repetir UUID no duplica.

> Demostración de 3:15: caso nuevo, regla y confirmación de persistencia.

Qué acreditamos y qué limitamos

Código, datos y evidencias accesibles

Acreditado técnicamente

- Captura y recorrido entre servicios.
- Consultas y comparación territorial.
- Modelos, pipeline y test conservado.
- Orientación y acción local explicables.

Límites

- Muestra pequeña y no aleatoria.
- Rentas agregadas; salario regional.
- Backtest revisado y mejora pequeña.
- Sin concesión ni disponibilidad garantizada.

Diferencias con clase: MLP sklearn, cliente Kafka y acceso WebHDFS.

> Repositorio, informe y comandos de reproducción. Preguntas.