¿Dónde puede vivir la juventud?

BDA + SBD · Recogida, almacenamiento y análisis

Referencias verificables para comparar municipios

Bilbao 2024 T4: 930,31 € de renta / 1.564 € de salario autonómico = 59,48 % en un escenario común.

Demostración de datos, servicios e indicadores. Duración no fijada en el PDF; ajustar al criterio docente.

Fuentes y unidades

No todos los registros representan una vivienda

Recogida

- JSON monetario EMAL: tres capitales.
- HTML: 17 anuncios de dos portales.
- Visesa/Etxebide: 621 promociones.
- INE y OVJ: territorio y contexto.

Conservación

- URL, fecha UTC y estado HTTP.
- Bytes y SHA-256.
- Nulos y rechazos explícitos.
- Sin afirmar disponibilidad actual.

> Demostración: un JSON API y un HTML archivado.

Arquitectura de datos

El recorrido que evaluamos en BDA y SBD

Capturar

JSON / HTML / XLSX / CSV

Conservar

Originales y derivados en HDFS

Analizar

Kafka → MongoDB → vistas

- Normalizar identidades y municipios antes de publicar.
- Verificar recuperación y conservar procedencia.
- Separar anuncios, promociones y agregados.

HDFS → Kafka → MongoDB

Guardar, recuperar, transportar y persistir

638
Registros vivienda: 621 + 17

3
Estadísticas API separadas

0
Duplicados nuevos en recarga

- HDFS raw/processed y recuperación idéntica.
- Consumidor confirma offset después de persistir.
- Upsert e identidades estables ante reentrega.

> Mostrar informe real conservado o ejecución de ensayo identificada.

MongoDB: modelado y limpieza

Documentos heterogéneos, relaciones explícitas

Modelado

- viviendas y municipios unidos por INE.
- Características y procedencia anidadas.
- EMAL / OVJ mediante referencia.
- API monetaria en colección separada.

Limpieza

- Duplicados por fuente e identidad.
- Nulos sin inventar medidas.
- Tipos y formatos observados.
- Derivados cuando son calculables.

CRUD comprobado en casos aislados; carga y recarga mediante upsert.

Consultas y agregaciones

Preguntas útiles con salidas reproducibles

Cinco consultas

Bilbao: 6 anuncios.

Hasta 750 €: 1.

Bilbao / ≤2.000 € / ≥55 m²: 4.

Habitaciones y señal temporal en array.

Tres pipelines

Estadísticas municipales.

Cruce territorial.

Distribuciones y top con $facet.

$group, $lookup, $unwind y otras etapas.

Una consulta vacía puede reflejar un campo no publicado.

Índices y consistencia

Medir el trabajo y justificar la atomicidad

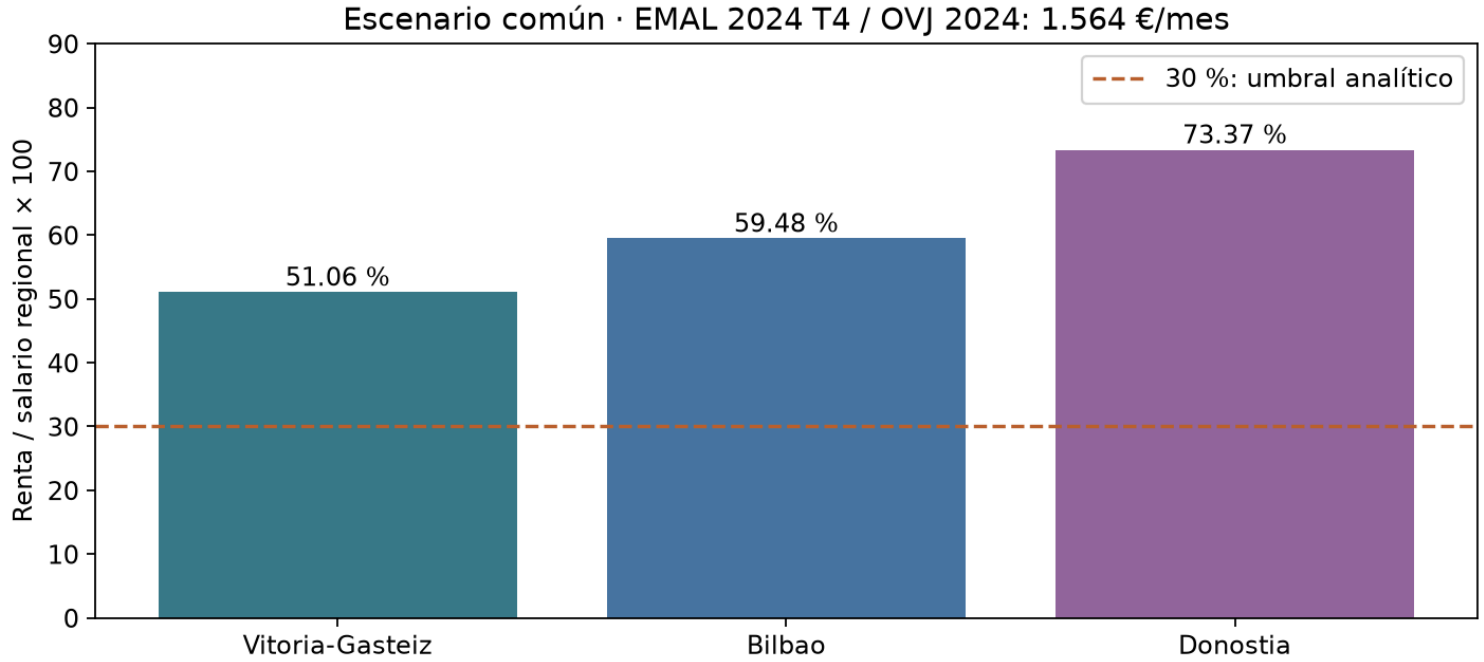
638	4	0 ms
COLLSCAN: examinados	IXSCAN: examinados	Tiempo medido en ambos

Los dos planes devuelven cuatro documentos. No se cuantifica aceleración temporal.

100 incrementos concurrentes sobre copia aislada: operación atómica de un documento; no demanda real ni transacción global.

Comparación territorial

Mismo ingreso de referencia; datos del mismo año



Escenario EMAL 2024 T4 / salario autonómico 2024. No esfuerzo individual observado.

Demostrar y entregar

Código, datos, arquitectura e informe

- Mostrar JSON API, HTML y metadatos de captura.
- Enseñar recuperación HDFS e informe de Kafka/MongoDB.
- Reentrega: 638 registros conservados; API separada mantiene tres.
- Abrir visor territorial, consultas, explain y tres capitales.
- Entregar originales, código, resultados y acceso o reconstrucción de los datos en servicios según lo acordado.

> Si falla un servicio: identificarlo y mostrar evidencia conservada con su fecha.

Conclusiones y límites

Responder al reto con el alcance de los datos

Resultado

Vitoria: 51,06 %.

Bilbao: 59,48 %.

Donostia: 73,37 %.

Escenario común EMAL/OVJ de 2024.

Límites

Salario autonómico, no municipal.

17 anuncios no representativos.

Promociones no implican disponibilidad.

Precios pedidos distintos de contratos.

APIs de Kafka/HDFS distintas de clase; mismas funciones exigidas.